Veri Madenciliği Projesi: Telco Müşteri Kaybı (Customer Churn)

Grup Çalışması

2026-05-22

- 1 A) Problem Tanımı
  - 1.1 Araştırma Soruları
  - 1.2 Modelleme Yaklaşımı
- 2 B) Veri Seti Tanıtımı
  - 2.1 Verinin Yüklenmesi
  - 2.2 İlk 5 Gözlem
  - 2.3 Gözlem ve Değişken Sayısı
  - 2.4 Değişken Türleri
  - 2.5 Özet İstatistikler
- 3 Veri Görselleştirme
  - 3.1 Churn Dağılımı
  - 3.2 Kontrat Türüne Göre Churn
  - 3.3 Aylık Ödeme Dağılımı
  - 3.4 Churn Durumuna Göre Aylık Ödeme Boxplot
  - 3.5 Hizmet Süresi ve Aylık Ödeme İlişkisi
- 4 C) Veri Ön İşleme
  - 4.1 Gereksiz Değişkenin Çıkarılması
  - 4.2 Veri Tipi Dönüşümü
  - 4.3 Eksik Veri Analizi
  - 4.4 Kategorik Değişkenlerin Faktöre Dönüştürülmesi
  - 4.5 Aykırı Değer Analizi
  - 4.6 Tutarsızlıkların Kontrolü
  - 4.7 Korelasyon Analizi
  - 4.8 Modelleme İçin Veri Hazırlığı
  - 4.9 Dummy Değişken Dönüşümü
  - 4.10 Standardizasyon
- 5 D) Modelleme
  - 5.1 Model 1: SVM
  - 5.2 SVM Tahminleri
  - 5.3 Model 2: KNN
- 6 E) Model Değerlendirme, Sonuç ve Yorum
  - 6.1 Sonuçların Yorumu
  - 6.2 Hangi Model Daha İyi?
  - 6.3 Beklenen ve Beklenmeyen Bulgular
  - 6.4 Veri Setinin Sınırlılıkları
  - 6.5 Gerçek Hayatta Kullanımı
- 7 Genel Sonuç

1 A) Problem Tanımı

Bu projede telekomünikasyon sektöründe müşterinin aldığı hizmeti bırakıp bırakmayacağı, yani **customer churn** problemi incelenmiştir. Churn, bir müşterinin şirketten ayrılması veya hizmeti kullanmayı bırakması anlamına gelir.

Bu problem işletmeler için önemlidir. Çünkü mevcut müşteriyi elde tutmak, yeni müşteri kazanmaktan çoğu zaman daha düşük maliyetlidir. Bu nedenle hangi müşterilerin ayrılma ihtimalinin yüksek olduğunu önceden tahmin etmek, işletmelerin müşteri kaybını azaltmasına yardımcı olabilir.

Bu proje bir **sınıflandırma problemidir**. Çünkü hedef değişken olan `Churn`, müşterinin ayrılıp ayrılmadığını göstermektedir:

- `Yes` : Müşteri hizmeti bırakmıştır.
- `No` : Müşteri hizmeti bırakmamıştır.

Bu çalışmada amaç, müşteri özelliklerine bakarak müşterinin churn durumunu tahmin etmektir.

1.1 Araştırma Soruları

1. Hangi müşteri özellikleri churn ile ilişkilidir?
2. Kontrat türü, aylık ödeme ve hizmet süresi churn üzerinde etkili midir?
3. SVM ve KNN modellerinden hangisi daha başarılı sonuç verir?

1.2 Modelleme Yaklaşımı

Bu projede istatistiksel testlere girilmeden, veri madenciliği dersinde görülen sınıflandırma mantığına uygun olarak iki farklı algoritma uygulanmıştır. Amaç, müşterilerin `Churn` durumunu tahmin etmektir.

Kullanılan modeller:

1. **SVM (Support Vector Machine)**
2. **KNN (K-Nearest Neighbors)**

Bu modeller seçilmiştir çünkü ikisi de sınıflandırma problemlerinde kullanılabilir. Ayrıca KNN mesafe temelli bir algoritma olduğu için ders notlarında anlatılan standardizasyon işlemiyle uyumludur. SVM ise sınıfları ayırmaya çalışan güçlü bir sınıflandırma yöntemidir.

2 B) Veri Seti Tanıtımı

Kullanılan veri seti Kaggle üzerinden alınmıştır:

Veri seti adı: Telco Customer Churn
Kaynak: https://www.kaggle.com/datasets/blastchar/telco-customer-churn (https://www.kaggle.com/datasets/blastchar/telco-customer-churn)

Bu veri setinde bir telekom şirketine ait müşteri bilgileri yer almaktadır. Veri setinde müşterilerin demografik bilgileri, kullandıkları hizmetler, ödeme bilgileri ve churn durumu bulunmaktadır.

```
required_packages <- c("tidyverse", "caret", "corrplot", "e1071", "class")

for (pkg in required_packages) {
  if (!require(pkg, character.only = TRUE)) {
    install.packages(pkg, dependencies = TRUE)
    library(pkg, character.only = TRUE)
  }
}
```

2.1 Verinin Yüklenmesi

Not: Kaggle'dan indirilen dosya adı genellikle `WA_Fn-UseC_-Telco-Customer-Churn.csv` şeklindedir. Dosya R Markdown dosyası ile aynı klasöre konulmalıdır.

```
data <- read.csv("WA_Fn-UseC_-Telco-Customer-Churn.csv", stringsAsFactors = FALSE)
```

2.2 İlk 5 Gözlem

```
head(data, 5)
```

```
##   customerID gender SeniorCitizen Partner Dependents tenure PhoneService
## 1 7590-VHVEG Female             0     Yes         No      1           No
## 2 5575-GNVDE   Male             0      No         No     34          Yes
## 3 3668-QPYBK   Male             0      No         No      2          Yes
## 4 7795-CFOCW   Male             0      No         No     45           No
## 5 9237-HQITU Female             0      No         No      2          Yes
##      MultipleLines InternetService OnlineSecurity OnlineBackup DeviceProtection
## 1 No phone service             DSL             No          Yes               No
## 2               No             DSL            Yes           No              Yes
## 3               No             DSL            Yes          Yes               No
## 4 No phone service             DSL            Yes           No              Yes
## 5               No     Fiber optic             No           No               No
##   TechSupport StreamingTV StreamingMovies       Contract PaperlessBilling
## 1          No          No              No Month-to-month              Yes
## 2          No          No              No       One year               No
## 3          No          No              No Month-to-month              Yes
## 4         Yes          No              No       One year               No
## 5          No          No              No Month-to-month              Yes
##               PaymentMethod MonthlyCharges TotalCharges Churn
## 1          Electronic check          29.85        29.85    No
## 2              Mailed check          56.95      1889.50    No
## 3              Mailed check          53.85       108.15   Yes
## 4 Bank transfer (automatic)          42.30      1840.75    No
## 5          Electronic check          70.70       151.65   Yes
```

2.3 Gözlem ve Değişken Sayısı

```
n <- nrow(data)
p <- ncol(data)

n
```

```
## [1] 7043
```

```
p
```

```
## [1] 21
```

Veri setinde 7043 gözlem ve 21 değişken bulunmaktadır. Bu nedenle proje yönergesinde istenen minimum 200 gözlem ve minimum 10 değişken şartını karşılamaktadır.

2.4 Değişken Türleri

```
str(data)
```

```
## 'data.frame':    7043 obs. of  21 variables:
##  $ customerID      : chr  "7590-VHVEG" "5575-GNVDE" "3668-QPYBK" "7795-CFOCW" ...
##  $ gender          : chr  "Female" "Male" "Male" "Male" ...
##  $ SeniorCitizen   : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Partner         : chr  "Yes" "No" "No" "No" ...
##  $ Dependents      : chr  "No" "No" "No" "No" ...
##  $ tenure          : int  1 34 2 45 2 8 22 10 28 62 ...
##  $ PhoneService    : chr  "No" "Yes" "Yes" "No" ...
##  $ MultipleLines   : chr  "No phone service" "No" "No" "No phone service" ...
##  $ InternetService : chr  "DSL" "DSL" "DSL" "DSL" ...
##  $ OnlineSecurity  : chr  "No" "Yes" "Yes" "Yes" ...
##  $ OnlineBackup    : chr  "Yes" "No" "Yes" "No" ...
##  $ DeviceProtection: chr  "No" "Yes" "No" "Yes" ...
##  $ TechSupport     : chr  "No" "No" "No" "Yes" ...
##  $ StreamingTV     : chr  "No" "No" "No" "No" ...
##  $ StreamingMovies : chr  "No" "No" "No" "No" ...
##  $ Contract        : chr  "Month-to-month" "One year" "Month-to-month" "One year" ...
##  $ PaperlessBilling: chr  "Yes" "No" "Yes" "No" ...
##  $ PaymentMethod   : chr  "Electronic check" "Mailed check" "Mailed check" "Bank transfer (automatic)" ...
##  $ MonthlyCharges  : num  29.9 57 53.9 42.3 70.7 ...
##  $ TotalCharges    : num  29.9 1889.5 108.2 1840.8 151.7 ...
##  $ Churn           : chr  "No" "No" "Yes" "No" ...
```

Veri setinde hem kategorik hem de sayısal değişkenler bulunmaktadır.

Sayısal değişken örnekleri:

- `tenure` : Müşterinin şirkette kaldığı ay sayısı
- `MonthlyCharges` : Aylık ödeme miktarı
- `TotalCharges` : Toplam ödeme miktarı

Kategorik değişken örnekleri:

- `gender` : Cinsiyet
- `Partner` : Partner durumu
- `InternetService` : İnternet hizmeti türü
- `Contract` : Kontrat türü
- `PaymentMethod` : Ödeme yöntemi
- `Churn` : Müşterinin ayrılıp ayrılmadığı

2.5 Özet İstatistikler

```
summary(data)
```

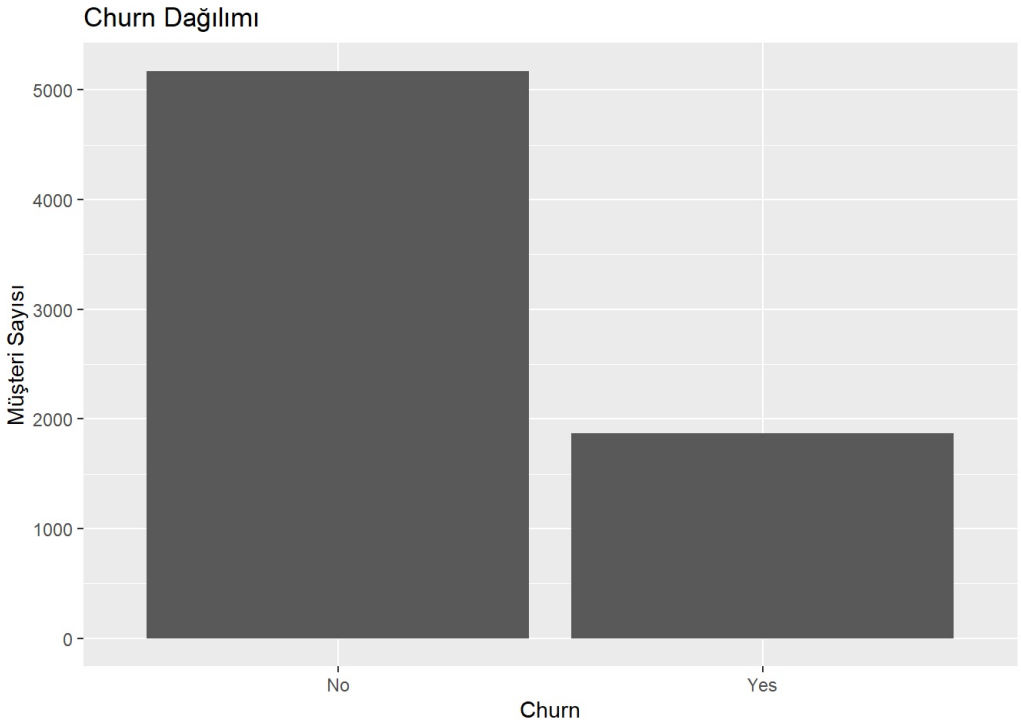
```
##      customerID         gender     SeniorCitizen         Partner
##  Length   :7043   Length   :7043   Min.   :0.0000   Length   :7043
##  N.unique :7043   N.unique :   2   1st Qu.:0.0000   N.unique :   2
##  N.blank  :   0   N.blank  :   0   Median :0.0000   N.blank  :   0
##  Min.nchar:  10   Min.nchar:   4   Mean   :0.1621   Min.nchar:   2
##  Max.nchar:  10   Max.nchar:   6   3rd Qu.:0.0000   Max.nchar:   3
##                                    Max.   :1.0000
##
##      Dependents       tenure         PhoneService    MultipleLines
##  Length   :7043   Min.   : 0.00   Length   :7043   Length   :7043
##  N.unique :   2   1st Qu.: 9.00   N.unique :   2   N.unique :   3
##  N.blank  :   0   Median :29.00   N.blank  :   0   N.blank  :   0
##  Min.nchar:   2   Mean   :32.37   Min.nchar:   2   Min.nchar:   2
##  Max.nchar:   3   3rd Qu.:55.00   Max.nchar:   3   Max.nchar:  16
##                   Max.   :72.00
##
##   InternetService   OnlineSecurity    OnlineBackup   DeviceProtection
##  Length   :7043   Length   :7043   Length   :7043   Length   :7043
##  N.unique :   3   N.unique :   3   N.unique :   3   N.unique :   3
##  N.blank  :   0   N.blank  :   0   N.blank  :   0   N.blank  :   0
##  Min.nchar:   2   Min.nchar:   2   Min.nchar:   2   Min.nchar:   2
##  Max.nchar:  11   Max.nchar:  19   Max.nchar:  19   Max.nchar:  19
##
##
##     TechSupport      StreamingTV    StreamingMovies      Contract
##  Length   :7043   Length   :7043   Length   :7043   Length   :7043
##  N.unique :   3   N.unique :   3   N.unique :   3   N.unique :   3
##  N.blank  :   0   N.blank  :   0   N.blank  :   0   N.blank  :   0
##  Min.nchar:   2   Min.nchar:   2   Min.nchar:   2   Min.nchar:   8
##  Max.nchar:  19   Max.nchar:  19   Max.nchar:  19   Max.nchar:  14
##
##
##   PaperlessBilling   PaymentMethod  MonthlyCharges    TotalCharges
##  Length   :7043    Length   :7043   Min.   : 18.25   Min.   :  18.8
##  N.unique :   2    N.unique :   4   1st Qu.: 35.50   1st Qu.: 401.4
##  N.blank  :   0    N.blank  :   0   Median : 70.35   Median :1397.5
##  Min.nchar:   2    Min.nchar:  12   Mean   : 64.76   Mean   :2283.3
##  Max.nchar:   3    Max.nchar:  25   3rd Qu.: 89.85   3rd Qu.:3794.7
##                                     Max.   :118.75   Max.   :8684.8
##                                                      NAs    :11
##        Churn
##  Length   :7043
##  N.unique :   2
##  N.blank  :   0
##  Min.nchar:   2
##  Max.nchar:   3
##
##
```

3 Veri Görselleştirme

Bu bölümde veri setindeki bazı değişkenler farklı grafik türleriyle gösterilmiştir.

3.1 Churn Dağılımı

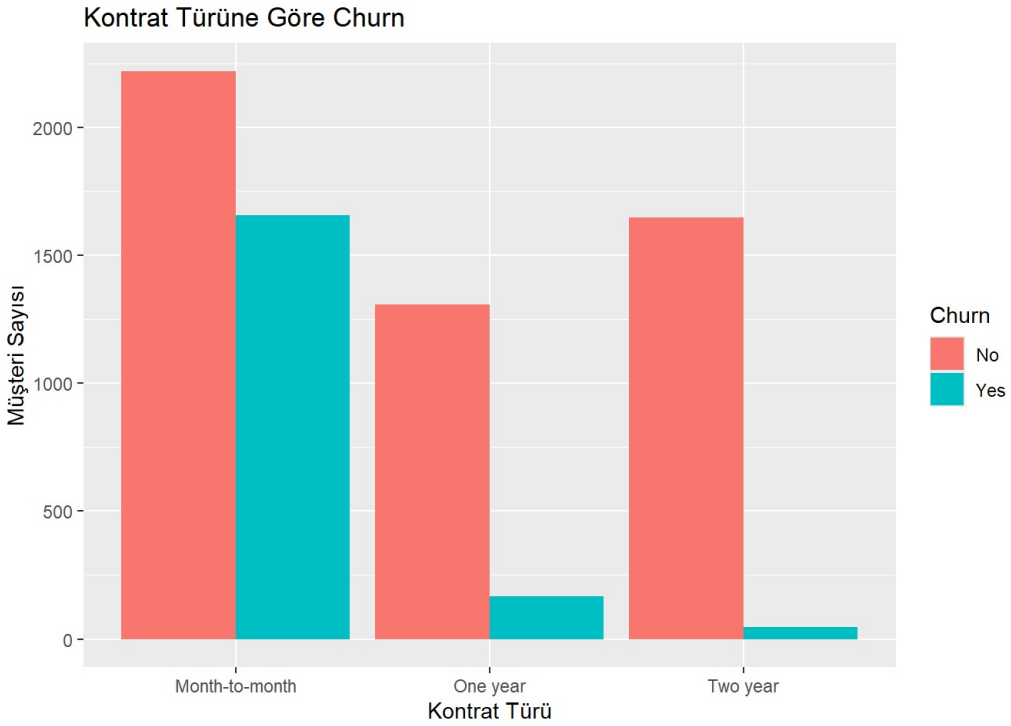
```
ggplot(data, aes(x = Churn)) +
  geom_bar() +
  labs(title = "Churn Dağılımı", x = "Churn", y = "Müşteri Sayısı")
```



Yorum: Bu grafik müşterilerin kaçının hizmeti bırakıp bırakmadığını göstermektedir. Genellikle churn olmayan müşteri sayısı daha fazladır. Bu durum veri setinde sınıf dengesizliği olabileceğini gösterir.

3.2 Kontrat Türüne Göre Churn

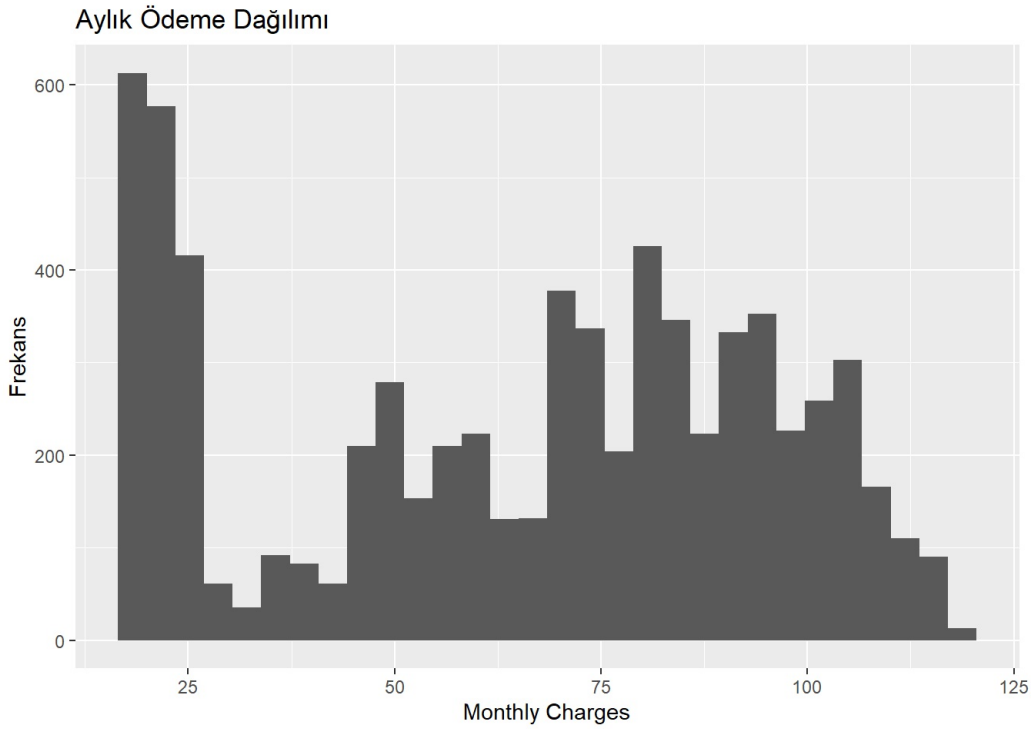
```
ggplot(data, aes(x = Contract, fill = Churn)) +
  geom_bar(position = "dodge") +
  labs(title = "Kontrat Türüne Göre Churn", x = "Kontrat Türü", y = "Müşteri Sayısı")
```



Yorum: Aylık kontratı olan müşterilerde churn oranının daha yüksek olması beklenmektedir. Uzun süreli kontratlar müşteri bağlılığını artırabilir.

3.3 Aylık Ödeme Dağılımı

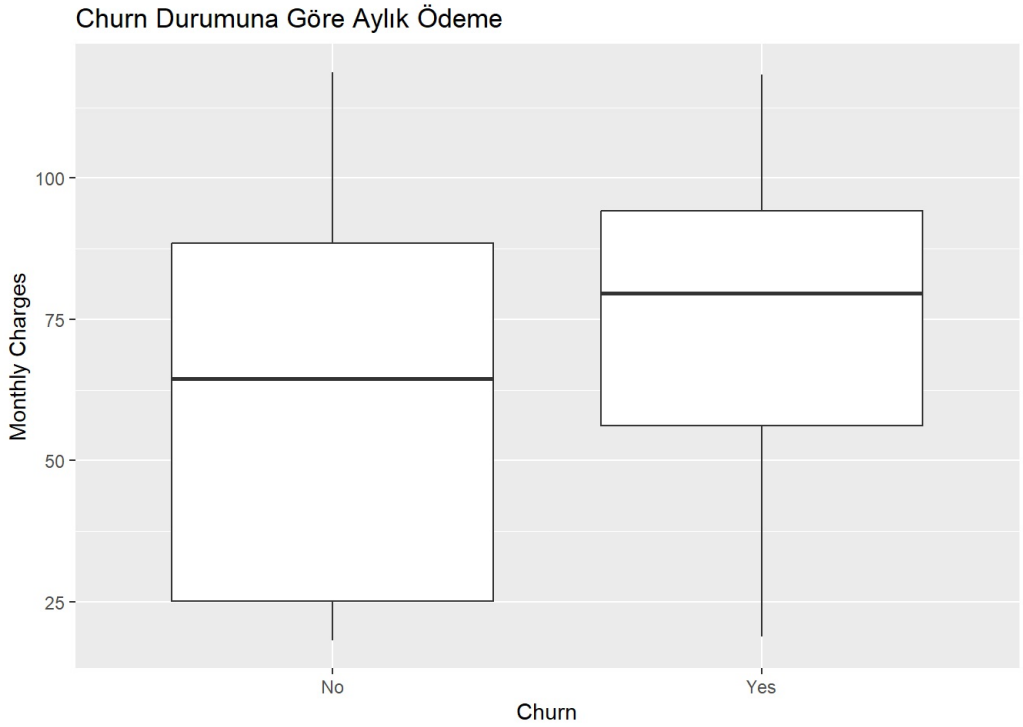
```
ggplot(data, aes(x = MonthlyCharges)) +
  geom_histogram(bins = 30) +
  labs(title = "Aylık Ödeme Dağılımı", x = "Monthly Charges", y = "Frekans")
```



Yorum: Bu grafik müşterilerin aylık ödeme miktarlarının dağılımını göstermektedir. Aylık ödeme miktarı churn tahmininde önemli bir değişken olabilir.

3.4 Churn Durumuna Göre Aylık Ödeme Boxplot

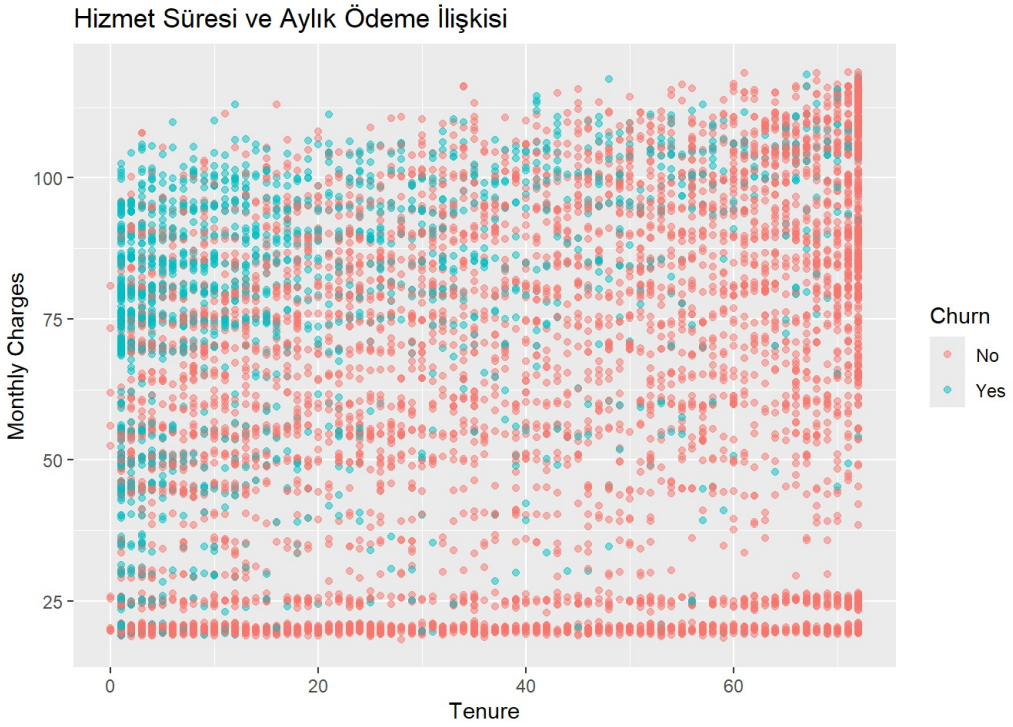
```
ggplot(data, aes(x = Churn, y = MonthlyCharges)) +
  geom_boxplot() +
  labs(title = "Churn Durumuna Göre Aylık Ödeme", x = "Churn", y = "Monthly Charges")
```



Yorum: Boxplot grafiği ile churn olan ve olmayan müşterilerin aylık ödeme dağılımları karşılaştırılmıştır. Eğer churn olan müşterilerin aylık ödemeleri daha yüksekse, bu durum aylık ücretin müşteri kaybı ile ilişkili olabileceğini gösterir.

3.5 Hizmet Süresi ve Aylık Ödeme İlişkisi

```
ggplot(data, aes(x = tenure, y = MonthlyCharges, color = Churn)) +
  geom_point(alpha = 0.5) +
  labs(title = "Hizmet Süresi ve Aylık Ödeme İlişkisi", x = "Tenure", y = "Monthly Charges")
```



Yorum: Scatter plot ile hizmet süresi ve aylık ödeme arasındaki ilişki gözlemlenmiştir. Churn olan müşterilerin hangi bölgelerde yoğunlaştığı bu grafik üzerinden incelenebilir.

4 C) Veri Ön İşleme

Veri ön işleme, veri madenciliği sürecinin önemli aşamalarından biridir. Bu bölümde eksik veri, aykırı değer, tutarsızlık, dönüşüm ve özellik seçimi işlemleri yapılmıştır.

4.1 Gereksiz Değişkenin Çıkarılması

`customerID` değişkeni müşteri kimlik numarasıdır. Tahmin açısından anlamlı bir bilgi taşımadığı için veri setinden çıkarılmıştır.

```
data <- data %>% select(-customerID)
```

4.2 Veri Tipi Dönüşümü

`TotalCharges` değişkeni veri setinde karakter olarak gelmektedir. Bu değişken sayısal hale getirilmiştir.

```
data$TotalCharges <- as.numeric(data$TotalCharges)
```

4.3 Eksik Veri Analizi

```
missing_count <- colSums(is.na(data))
missing_percent <- round(colSums(is.na(data)) / nrow(data) * 100, 2)

missing_table <- data.frame(
  Variable = names(missing_count),
  Missing_Count = missing_count,
  Missing_Percent = missing_percent
)

missing_table
```

```
##                         Variable Missing_Count Missing_Percent
## gender                     gender             0            0.00
## SeniorCitizen       SeniorCitizen             0            0.00
## Partner                   Partner             0            0.00
## Dependents             Dependents             0            0.00
## tenure                     tenure             0            0.00
## PhoneService         PhoneService             0            0.00
## MultipleLines       MultipleLines             0            0.00
## InternetService   InternetService             0            0.00
## OnlineSecurity     OnlineSecurity             0            0.00
## OnlineBackup         OnlineBackup             0            0.00
## DeviceProtection DeviceProtection             0            0.00
## TechSupport           TechSupport             0            0.00
## StreamingTV           StreamingTV             0            0.00
## StreamingMovies   StreamingMovies             0            0.00
## Contract                 Contract             0            0.00
## PaperlessBilling PaperlessBilling             0            0.00
## PaymentMethod       PaymentMethod             0            0.00
## MonthlyCharges     MonthlyCharges             0            0.00
## TotalCharges         TotalCharges            11            0.16
## Churn                       Churn             0            0.00
```

Yorum: Eksik veri analizi sonucunda hangi değişkenlerde eksik değer olduğu incelenmiştir. `TotalCharges` değişkeninde eksik değer varsa, bu değerler medyan ile doldurulmuştur. Medyan yöntemi, aykırı değerlere ortalamaya göre daha dayanıklı olduğu için tercih edilmiştir.

```
data$TotalCharges[is.na(data$TotalCharges)] <- median(data$TotalCharges, na.rm = TRUE)
```

4.4 Kategorik Değişkenlerin Faktöre Dönüştürülmesi

```
data <- data %>% mutate_if(is.character, as.factor)
str(data)
```

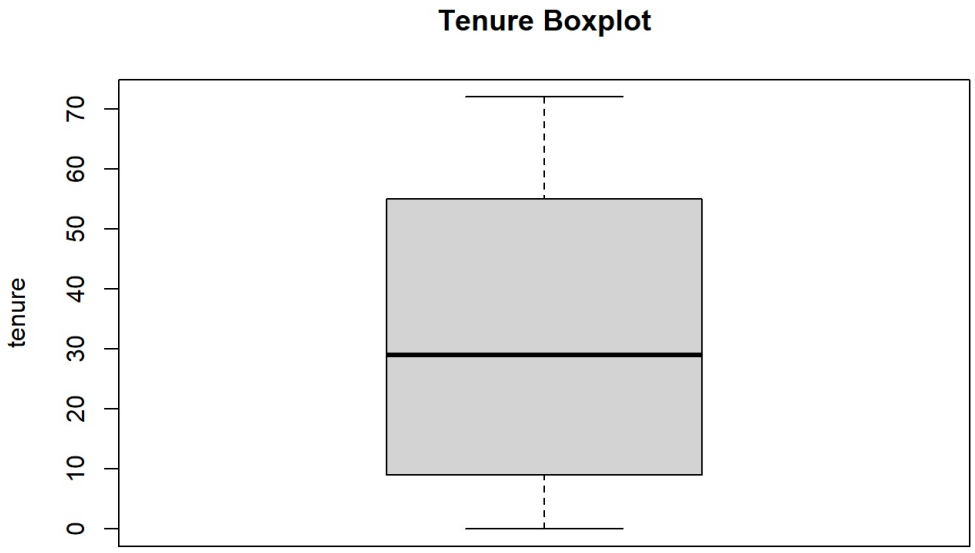
```
## 'data.frame':    7043 obs. of  20 variables:
##  $ gender          : Factor w/ 2 levels "Female","Male": 1 2 2 2 1 1 2 1 1 2 ...
##  $ SeniorCitizen   : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Partner         : Factor w/ 2 levels "No","Yes": 2 1 1 1 1 1 1 2 1 ...
##  $ Dependents      : Factor w/ 2 levels "No","Yes": 1 1 1 1 1 1 2 1 1 2 ...
##  $ tenure          : int  1 34 2 45 2 8 22 10 28 62 ...
##  $ PhoneService    : Factor w/ 2 levels "No","Yes": 1 2 2 1 2 2 2 1 2 2 ...
##  $ MultipleLines   : Factor w/ 3 levels "No","No phone service",..: 2 1 1 2 1 3 3 2 3 1 ...
##  $ InternetService : Factor w/ 3 levels "DSL","Fiber optic",..: 1 1 1 1 2 2 2 1 2 1 ...
##  $ OnlineSecurity  : Factor w/ 3 levels "No","No internet service",..: 1 3 3 3 1 1 1 3 1 3 ...
##  $ OnlineBackup    : Factor w/ 3 levels "No","No internet service",..: 3 1 3 1 1 1 3 1 1 3 ...
##  $ DeviceProtection: Factor w/ 3 levels "No","No internet service",..: 1 3 1 3 1 3 1 1 3 1 ...
##  $ TechSupport     : Factor w/ 3 levels "No","No internet service",..: 1 1 1 3 1 1 1 1 3 1 ...
##  $ StreamingTV     : Factor w/ 3 levels "No","No internet service",..: 1 1 1 1 1 3 3 1 3 1 ...
##  $ StreamingMovies : Factor w/ 3 levels "No","No internet service",..: 1 1 1 1 1 3 1 1 3 1 ...
##  $ Contract        : Factor w/ 3 levels "Month-to-month",..: 1 2 1 2 1 1 1 1 1 2 ...
##  $ PaperlessBilling: Factor w/ 2 levels "No","Yes": 2 1 2 1 2 2 2 1 2 1 ...
##  $ PaymentMethod   : Factor w/ 4 levels "Bank transfer (automatic)",..: 3 4 4 1 3 3 2 4 3 1 ...
##  $ MonthlyCharges  : num  29.9 57 53.9 42.3 70.7 ...
##  $ TotalCharges    : num  29.9 1889.5 108.2 1840.8 151.7 ...
##  $ Churn           : Factor w/ 2 levels "No","Yes": 1 1 2 1 2 2 1 1 2 1 ...
```

4.5 Aykırı Değer Analizi

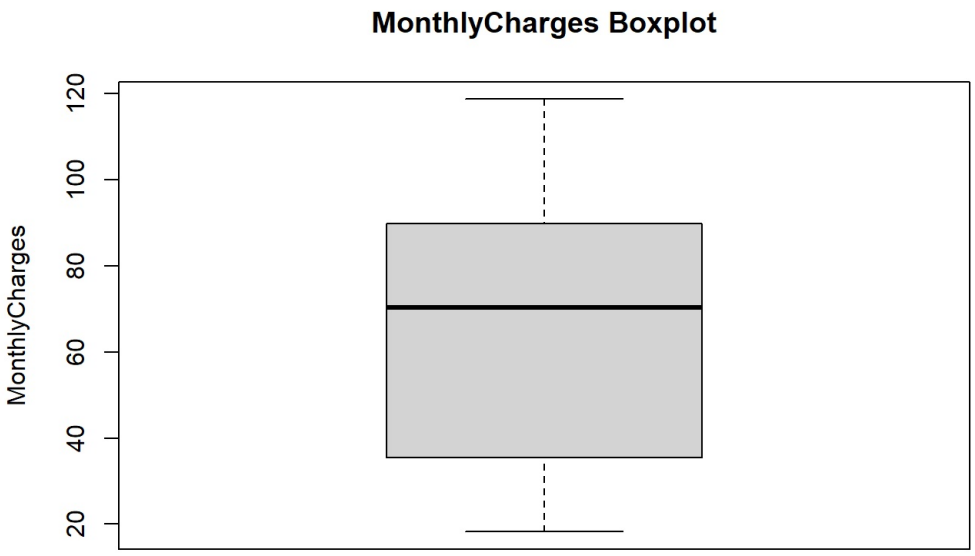
Sayısal değişkenler için boxplot ile aykırı değer analizi yapılmıştır.

```
numeric_vars <- data %>% select(where(is.numeric))

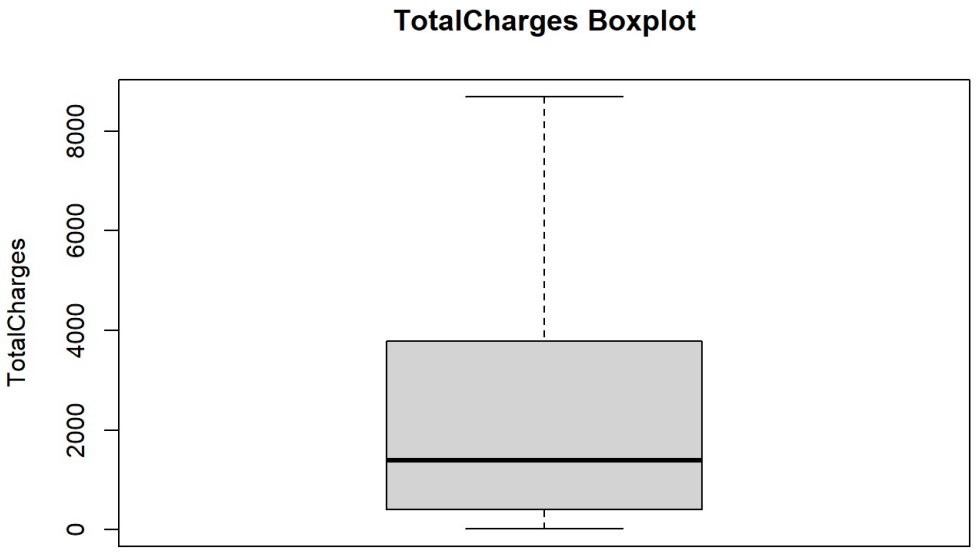
boxplot(numeric_vars$tenure, main = "Tenure Boxplot", ylab = "tenure")
```




```
boxplot(numeric_vars$MonthlyCharges, main = "MonthlyCharges Boxplot", ylab = "MonthlyCharges")
```




```
boxplot(numeric_vars$TotalCharges, main = "TotalCharges Boxplot", ylab = "TotalCharges")
```



Yorum: Boxplot grafiklerinde aykırı değerler incelenmiştir. Bu projede aykırı değerler doğrudan silinmemiştir. Çünkü aylık ödeme veya toplam ödeme gibi değişkenlerde yüksek değerler gerçek müşteri davranışını temsil edebilir. Bu nedenle modellemede bu gözlemler korunmuştur.

4.6 Tutarsızlıkların Kontrolü

```
summary(data$tenure)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    0.00    9.00   29.00   32.37   55.00   72.00
```

```
summary(data$MonthlyCharges)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   18.25   35.50   70.35   64.76   89.85  118.75
```

```
summary(data$TotalCharges)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    18.8   402.2  1397.5  2281.9  3786.6  8684.8
```

```
levels(data$Churn)
```

```
## [1] "No"  "Yes"
```

Yorum: Sayısal değişkenlerde negatif değer gibi mantıksız değer olup olmadığı kontrol edilmiştir. Kategorik değişkenlerde de sınıf isimleri incelenmiştir.

4.7 Korelasyon Analizi

Korelasyon analizi sayısal değişkenler arasındaki doğrusal ilişkiyi incelemek için kullanılmıştır.

```
cor_matrix <- cor(numeric_vars)
cor_matrix
```

```
##                SeniorCitizen     tenure MonthlyCharges TotalCharges
## SeniorCitizen     1.00000000 0.01656688      0.2201733    0.1026516
## tenure            0.01656688 1.00000000      0.2478999    0.8254641
## MonthlyCharges    0.22017334 0.24789986      1.0000000    0.6508643
## TotalCharges      0.10265159 0.82546409      0.6508643    1.0000000
```

```
corrplot(cor_matrix, method = "color", addCoef.col = "black", number.cex = 0.7)
```



Yorum: Korelasyon matrisi ile sayısal değişkenler arasındaki ilişki incelenmiştir. `tenure` ve `TotalCharges` arasında yüksek ilişki çıkması beklenebilir. Çünkü müşteri şirkette ne kadar uzun kalırsa toplam ödeme miktarı da genellikle artar.

4.8 Modelleme İçin Veri Hazırlığı

Hedef değişken olan `Churn` faktör olarak düzenlenmiştir.

```
data$Churn <- factor(data$Churn, levels = c("No", "Yes"))
```

Veri eğitim ve test olarak ikiye ayrılmıştır. Verinin %70'i eğitim, %30'u test için kullanılmıştır.

```
set.seed(123)
train_index <- createDataPartition(data$Churn, p = 0.70, list = FALSE)
train_data <- data[train_index, ]
test_data <- data[-train_index, ]
```

4.9 Dummy Değişken Dönüşümü

SVM ve KNN modelleri için kategorik değişkenler dummy değişkenlere dönüştürülmüştür.

```
dummy_model <- dummyVars(Churn ~ ., data = train_data)

train_x <- predict(dummy_model, newdata = train_data)
test_x <- predict(dummy_model, newdata = test_data)

train_model_data <- data.frame(train_x)
train_model_data$Churn <- train_data$Churn

test_model_data <- data.frame(test_x)
test_model_data$Churn <- test_data$Churn
```

4.10 Standardizasyon

SVM ve KNN modellerinde değişkenlerin ölçek farkını azaltmak için standardizasyon uygulanmıştır. Özellikle KNN mesafe temelli olduğu için standardizasyon önemlidir.

```
preprocess_model <- preProcess(train_model_data %>% select(-Churn), method = c("center", "scale"))

train_scaled <- predict(preprocess_model, train_model_data %>% select(-Churn))
test_scaled <- predict(preprocess_model, test_model_data %>% select(-Churn))

train_scaled$Churn <- train_model_data$Churn
test_scaled$Churn <- test_model_data$Churn
```

5 D) Modelleme

Bu projede iki farklı sınıflandırma modeli kullanılmıştır:

1. SVM (Support Vector Machine)
2. KNN (K-Nearest Neighbors)

Bu modeller seçilmiştir çünkü ikisi de sınıflandırma problemlerinde kullanılabilir. Bu çalışmada amaç, müşterinin `Churn` durumunu `Yes` veya `No` olarak tahmin etmektir.

5.1 Model 1: SVM

SVM, sınıfları birbirinden en iyi şekilde ayırmaya çalışan bir sınıflandırma algoritmasıdır. Bu projede müşteri churn durumunu tahmin etmek için kullanılmıştır.

```
svm_model <- svm(Churn ~ ., data = train_scaled, kernel = "radial")
svm_model
```

```
##
## Call:
## svm(formula = Churn ~ ., data = train_scaled, kernel = "radial")
##
##
## Parameters:
##    SVM-Type:  C-classification
##  SVM-Kernel:  radial
##        cost:  1
##
## Number of Support Vectors:  2436
```

5.2 SVM Tahminleri

```
svm_pred <- predict(svm_model, newdata = test_scaled)
svm_pred <- factor(svm_pred, levels = c("No", "Yes"))

svm_conf <- confusionMatrix(svm_pred, test_scaled$Churn, positive = "Yes")
svm_conf
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction   No  Yes
##        No  1421  273
##        Yes  131  287
##
##                Accuracy : 0.8087
##                  95% CI : (0.7913, 0.8253)
##     No Information Rate : 0.7348
##     P-Value [Acc > NIR] : 1.110e-15
##
##                   Kappa : 0.4658
##
##  Mcnemar's Test P-Value : 2.299e-12
##
##             Sensitivity : 0.5125
##             Specificity : 0.9156
##          Pos Pred Value : 0.6866
##          Neg Pred Value : 0.8388
##              Prevalence : 0.2652
##          Detection Rate : 0.1359
##    Detection Prevalence : 0.1979
##       Balanced Accuracy : 0.7140
##
##        'Positive' Class : Yes
##
```

5.3 Model 2: KNN

KNN, yeni bir gözlemi kendisine en yakın komşulara bakarak sınıflandıran mesafe temelli bir algoritmadır. Bu nedenle model kurulmadan önce standardizasyon yapılmıştır. Bu projede `k = 5` seçilmiştir.

```
train_knn_x <- train_scaled %>% select(-Churn)
test_knn_x <- test_scaled %>% select(-Churn)

knn_pred <- knn(
  train = train_knn_x,
  test = test_knn_x,
  cl = train_scaled$Churn,
  k = 5
)

knn_pred <- factor(knn_pred, levels = c("No", "Yes"))

knn_conf <- confusionMatrix(knn_pred, test_scaled$Churn, positive = "Yes")
knn_conf
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction   No  Yes
##        No  1308  266
##        Yes  244  294
##
##                Accuracy : 0.7585
##                  95% CI : (0.7397, 0.7766)
##     No Information Rate : 0.7348
##     P-Value [Acc > NIR] : 0.006942
##
##                   Kappa : 0.3725
##
##  Mcnemar's Test P-Value : 0.352425
##
##             Sensitivity : 0.5250
##             Specificity : 0.8428
##          Pos Pred Value : 0.5465
##          Neg Pred Value : 0.8310
##              Prevalence : 0.2652
##          Detection Rate : 0.1392
##    Detection Prevalence : 0.2547
##       Balanced Accuracy : 0.6839
##
##        'Positive' Class : Yes
##
```

6 E) Model Değerlendirme, Sonuç ve Yorum

Sınıflandırma modelleri için Accuracy, Precision, Recall ve Confusion Matrix değerleri kullanılmıştır.

```
svm_accuracy <- svm_conf$overall["Accuracy"]
svm_precision <- svm_conf$byClass["Precision"]
svm_recall <- svm_conf$byClass["Recall"]

knn_accuracy <- knn_conf$overall["Accuracy"]
knn_precision <- knn_conf$byClass["Precision"]
knn_recall <- knn_conf$byClass["Recall"]

comparison <- data.frame(
  Model = c("SVM", "KNN"),
  Accuracy = c(svm_accuracy, knn_accuracy),
  Precision = c(svm_precision, knn_precision),
  Recall = c(svm_recall, knn_recall)
)

comparison
```

```
##   Model  Accuracy Precision Recall
## 1   SVM 0.8087121 0.6866029 0.5125
## 2   KNN 0.7585227 0.5464684 0.5250
```

6.1 Sonuçların Yorumu

Bu projede müşteri kaybı problemi bir sınıflandırma problemi olarak ele alınmıştır. İlk olarak veri seti tanıtılmış, eksik veriler incelenmiş, gerekli dönüşümler yapılmış ve veri görselleştirilmiştir.

Modelleme aşamasında SVM ve KNN algoritmaları uygulanmıştır. İki modelin performansı Accuracy, Precision ve Recall değerleri ile karşılaştırılmıştır.

Accuracy ve Recall değerleri hangi modelde daha yüksekse, o model müşteri kaybını tahmin etmek için daha başarılı kabul edilebilir. Churn probleminde sadece genel doğruluk değil, churn olan müşterileri yakalamak da önemlidir. Bu nedenle Recall değeri ayrıca dikkate alınmıştır.

Grafikler ve model sonuçları dikkate alındığında özellikle `Contract`, `tenure`, `MonthlyCharges` ve `InternetService` gibi değişkenlerin churn tahmininde etkili olabileceği düşünülmektedir.

6.2 Hangi Model Daha İyi?

```
comparison[which.max(comparison$Accuracy), ]
```

```
##   Model  Accuracy Precision Recall
## 1   SVM 0.8087121 0.6866029 0.5125
```

Accuracy değeri en yüksek olan model genel başarı açısından daha iyi kabul edilmiştir. Ancak churn problemi için sadece accuracy yeterli olmayabilir. Çünkü churn olan müşterileri doğru yakalamak işletme açısından önemlidir. Bu nedenle Recall değeri de dikkate alınmalıdır.

6.3 Beklenen ve Beklenmeyen Bulgular

Beklenen bulgu olarak aylık kontratı olan müşterilerin churn oranının daha yüksek olması beklenmektedir. Çünkü uzun dönemli kontratlar müşteriyi firmaya daha bağlı hale getirebilir.

Ayrıca aylık ödeme miktarı yüksek olan müşterilerin churn olasılığının daha fazla çıkması da mantıklı bir sonuç olabilir. Çünkü yüksek fiyat müşteri memnuniyetsizliğini artırabilir.

Beklenmeyen bulgular model sonuçlarına göre yorumlanmalıdır. Örneğin bazı hizmetleri kullanan müşterilerin beklenenden daha fazla churn etmesi, hizmet kalitesi veya fiyatlandırma ile ilgili olabilir.

6.4 Veri Setinin Sınırlılıkları

Bu veri setinin bazı sınırlılıkları vardır:

- Veri tek bir telekom şirketine aittir.
- Müşteri memnuniyeti gibi psikolojik değişkenler bulunmamaktadır.
- Veride zaman bilgisi sınırlıdır.
- Churn nedenleri doğrudan yer almamaktadır.

6.5 Gerçek Hayatta Kullanımı

Bu çalışma gerçek hayatta müşteri kaybını azaltmak için kullanılabilir. Churn olasılığı yüksek müşteriler önceden tespit edilerek bu müşterilere özel kampanya, indirim veya müşteri hizmeti desteği sağlanabilir.

Örneğin:

- Aylık kontratı olan müşterilere uzun dönemli kontrat teklif edilebilir.
- Aylık ödemesi yüksek olan müşterilere indirim uygulanabilir.
- Yeni müşterilerin ilk aylarda ayrılmasını önlemek için özel destek verilebilir.

7 Genel Sonuç

Bu proje kapsamında Telco Customer Churn veri seti kullanılarak müşteri kaybı problemi incelenmiştir. Veri madenciliği sürecine uygun olarak veri seçimi, veri tanıtımı, veri ön işleme, görselleştirme, modelleme ve değerlendirme aşamaları uygulanmıştır.

Sonuç olarak, müşteri churn tahmini için SVM ve KNN modelleri karşılaştırılmıştır. Elde edilen sonuçlara göre en başarılı model belirlenmiş ve sonuçlar işletme açısından yorumlanmıştır.